Классификация рамановских спектров мозговой ткани методами машинного обучения

Команда: Gradient Island

Made with GAMMA

Что мы делали?

Проблема

Требовалось построить классификатор для трех экспериментальных групп (контроль, эндо, экзо) на зашумленных спектральных данных с сильной корреляцией внутри объектов (крыс), что делало обычную кросс-валидацию некорректной.

Цель

Разработать корректный пайплайн машинного обучения, который обобщается на новых животных, а не просто запоминает индивидуальные особенности.

Made with GAMMA

Формальная постановка задачи

Исследование сведено к задаче мультиклассовой классификации по трем группам: *control, endo, exo*.

$$F_1^{\text{macro}} = \frac{1}{3}\sum_{c\in C} F_1^{(c)}, \quad F_1^{(c)} = \frac{2\text{TP}_c}{2\text{TP}_c + \text{FP}_c + \text{FN}_c}$$

Основная цель оптимизации — максимизация макро-F1 метрики для достижения баланса между классами.

Made with GAMMA

Рамановские Спектракарты

Спектральные диапазоны

- **1500 см$^{-1}$:** 600–1800 см$^{-1}$ (отпечаток: белки, ДНК, липиды)
- **2900 см$^{-1}$:** 2800–3100 см$^{-1}$ (C-H колебания, липиды)

Объем данных

118 спектральных карт от 4 животных, что требует использования LOAO-валидации для предотвращения переобучения.

Made with GAMMA

Пайплайн предобработки данных

1. Агрегация

Усреднение пикселей карты в единый спектр.

2. Интерполяция

Приведение всех данных к сетке в 1500 точек.

3. Коррекция фона

Удаление флуоресценции через AsLS.

$$\hat{z} = \arg\min_{\mathbf{z}} \left[\mathbf{w}^\top (\mathbf{y} - \mathbf{z})^2 + \lambda \|\mathbf{D}^{(2)}\mathbf{z}\|^2 \right]$$

Made with GAMMA

Инжиниринг признаков

Биохимические полосы

Анализ отношений пиков Amide I/III и CH2/CH3.

Производные

Использование 1-й и 2-й производных для оценки скорости изменений.

Вейвлеты (db8)

Энергия и энтропия коэффициентов на 5 уровнях разложения.

Финальное признаковое пространство достигает 120 отобранных через LightGBM признаков.

Made with GAMMA

Стратегия LOAO-валидации

Для исключения биологической утечки данных мы используем *Leave-One-Animal-Out*: на каждом фолде все спектры одного животного тестируются на модели, обученной на остальных.

Фолд	Животное в тесте	Карт в тесте
1	Животное №1	36
2	Животное №2	33
3	Животное №3	14
4	Животное №4	33

Made with GAMMA

Стеканг 21 модели

Базовый уровень

Мы использовали 7 алгоритмов (XGBoost, LGBM, CatBoost, RF, Extra Trees, SVM, MLP) на 3 наборах признаков. Настройка проводилась через Optuna (50 итераций).

Мета-уровень

OOF-вероятности подаются в мета-модель (LogReg). Оптимизация порогов решения $\hat{y} = \arg \max_c (p_c / \theta_c)$ позволяет максимизировать точность.

Made with GAMMA

Результаты классификации

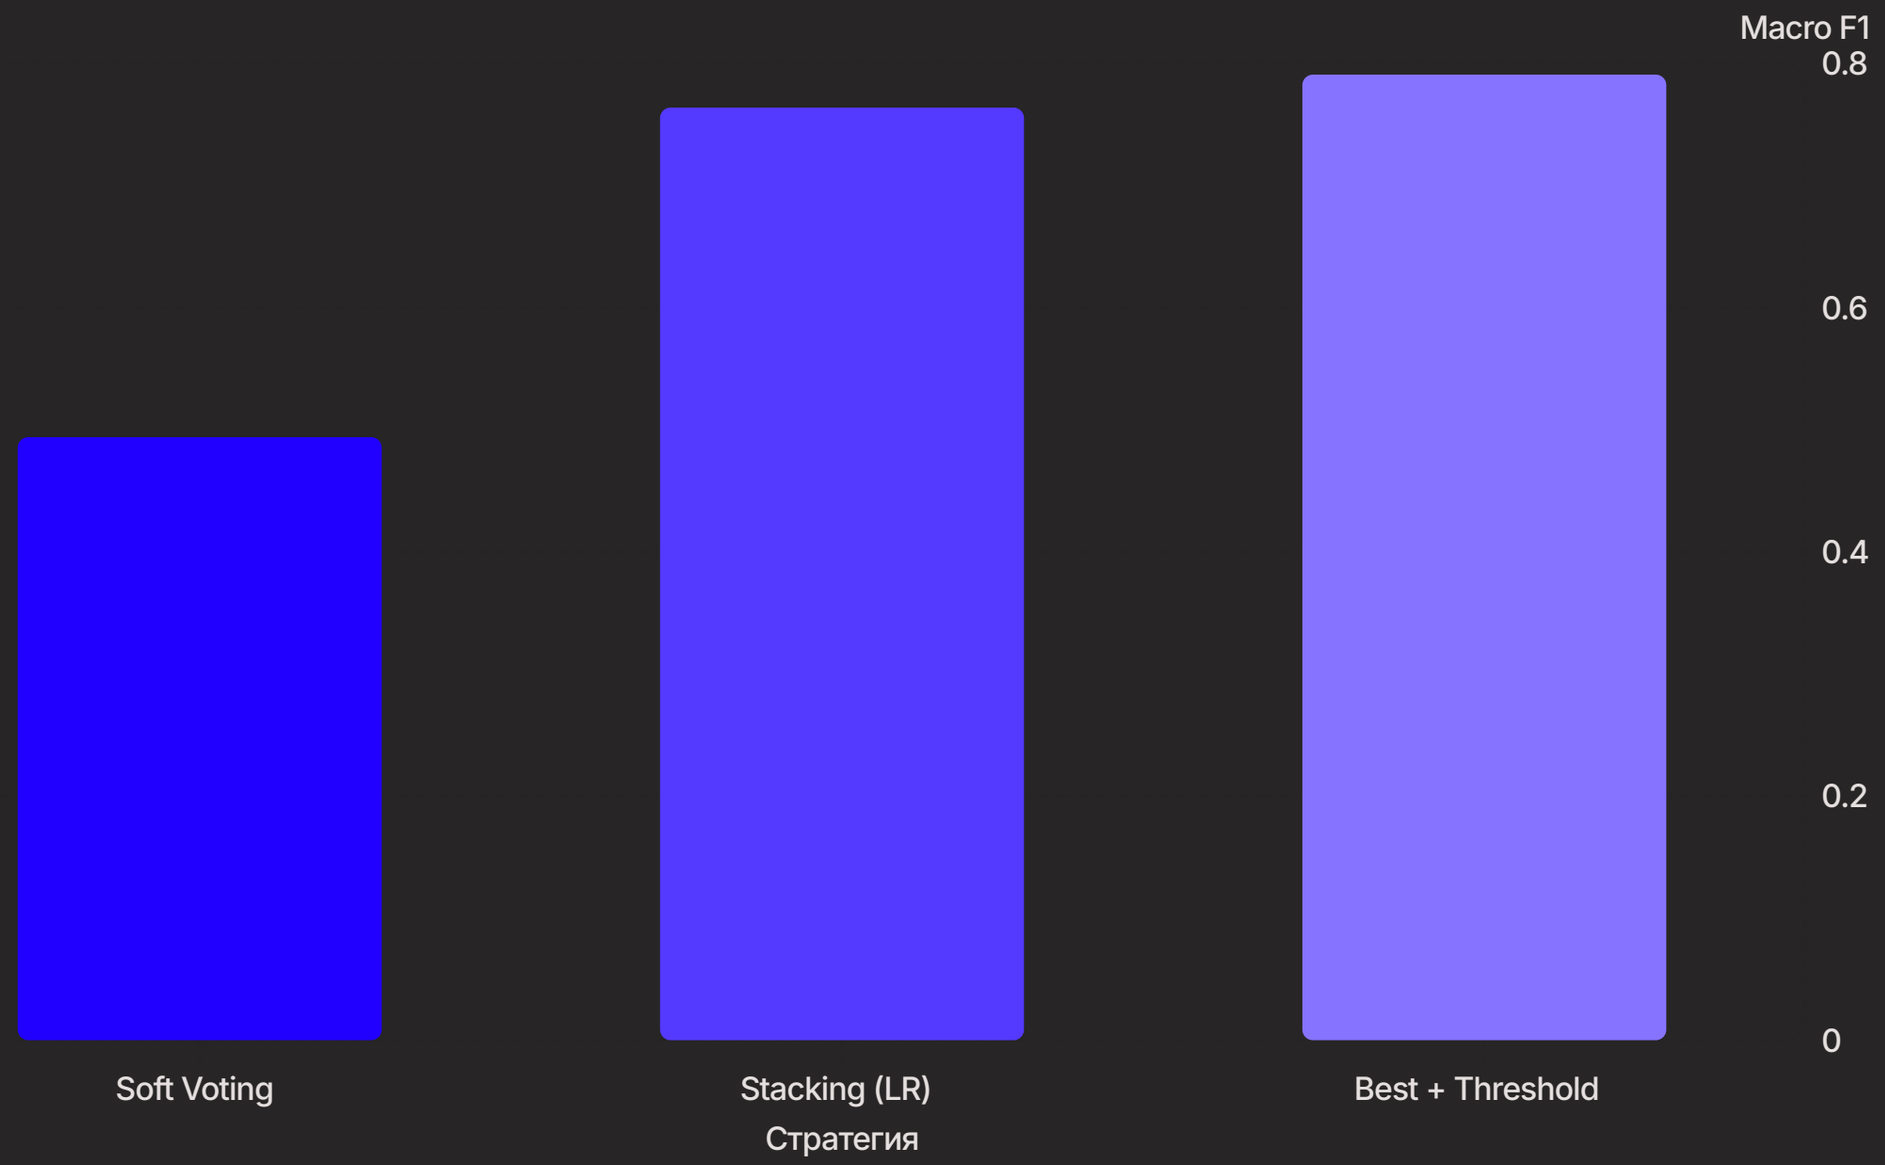

Стекинг с оптимизацией порогов показал наилучший результат (F1=0.791), обеспечив баланс классов, особенно для эндогенной экспрессии HSP70 (0.850).

Made with GAMMA

Заключение

Точность

Достигнут macro F1 = 0.791 благодаря стекингу.

Интерпретация

HSP70 меняет конформацию белков (Amide) и текучесть мембран (CH2/CH3).

Спасибо за внимание! Будем рады ответить на ваши вопросы.

Made with GAMMA