# Классификация рамановских спектров мозговой ткани методами машинного обучения

Команда: Gradient Island

Made with GAMMA

# Что мы делали?

## Проблема

Требовалось построить классификатор для трех экспериментальных групп (контроль, эндо, экзо) на зашумленных спектральных данных с сильной корреляцией внутри объектов (крыс), что делало обычную кросс-валидацию некорректной.

## Цель

Разработать корректный пайплайн машинного обучения, который обобщается на новых животных, а не просто запоминает индивидуальные особенности.

Made with GAMMA

# Формальная постановка задачи

Исследование сведено к задаче мультиклассовой классификации по трем группам: *control, endo, exo*.

$$F_1^{\text{macro}} = \frac{1}{3}\sum_{c\in C} F_1^{(c)}, \quad F_1^{(c)} = \frac{2\text{TP}_c}{2\text{TP}_c + \text{FP}_c + \text{FN}_c}$$

Основная цель оптимизации — максимизация макро-F1 метрики для достижения баланса между классами.

Made with GAMMA

# Рамановские Спектракарты

## Спектральные диапазоны

- **1500 см$^{-1}$:** 600–1800 см$^{-1}$ (отпечаток: белки, ДНК, липиды)
- **2900 см$^{-1}$:** 2800–3100 см$^{-1}$ (C-H колебания, липиды)

## Объем данных

118 спектральных карт от 4 животных, что требует использования LOAO-валидации для предотвращения переобучения.

Made with GAMMA

# Мапинг спектров на сетку

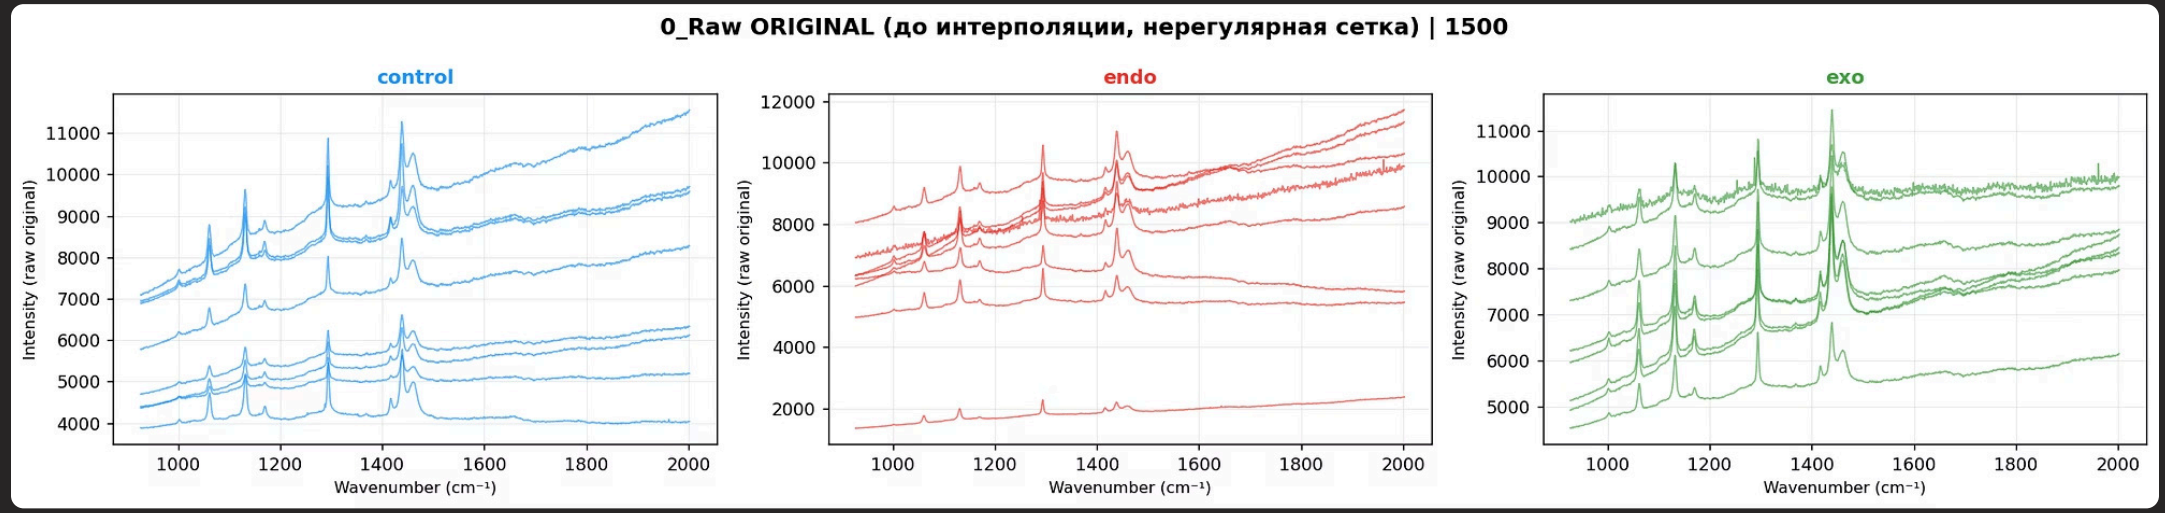


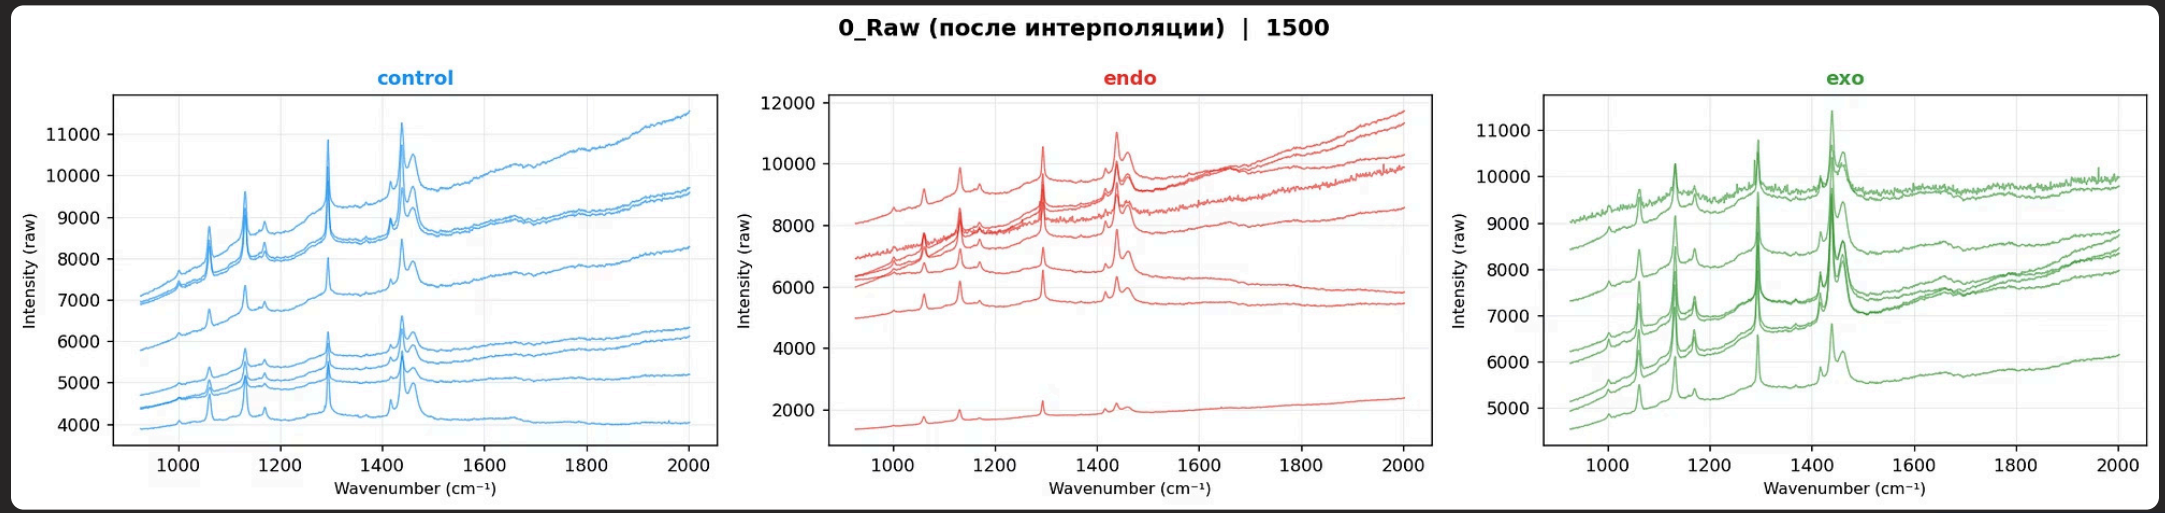


Made with GAMMA

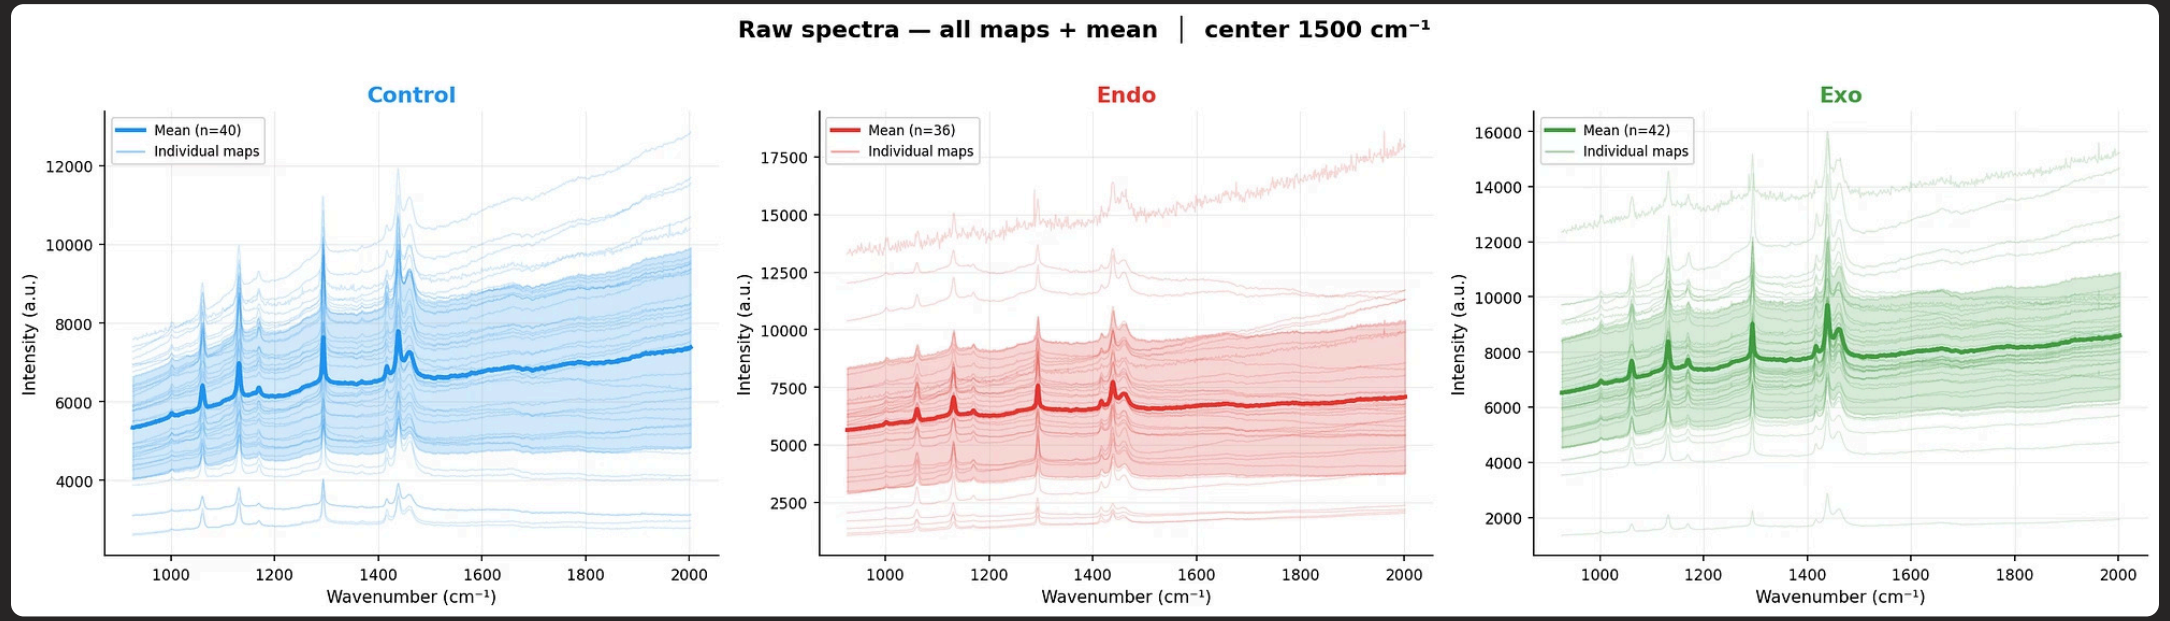


# Усреднение по картам

Made with GAMMA

# Baseline correction

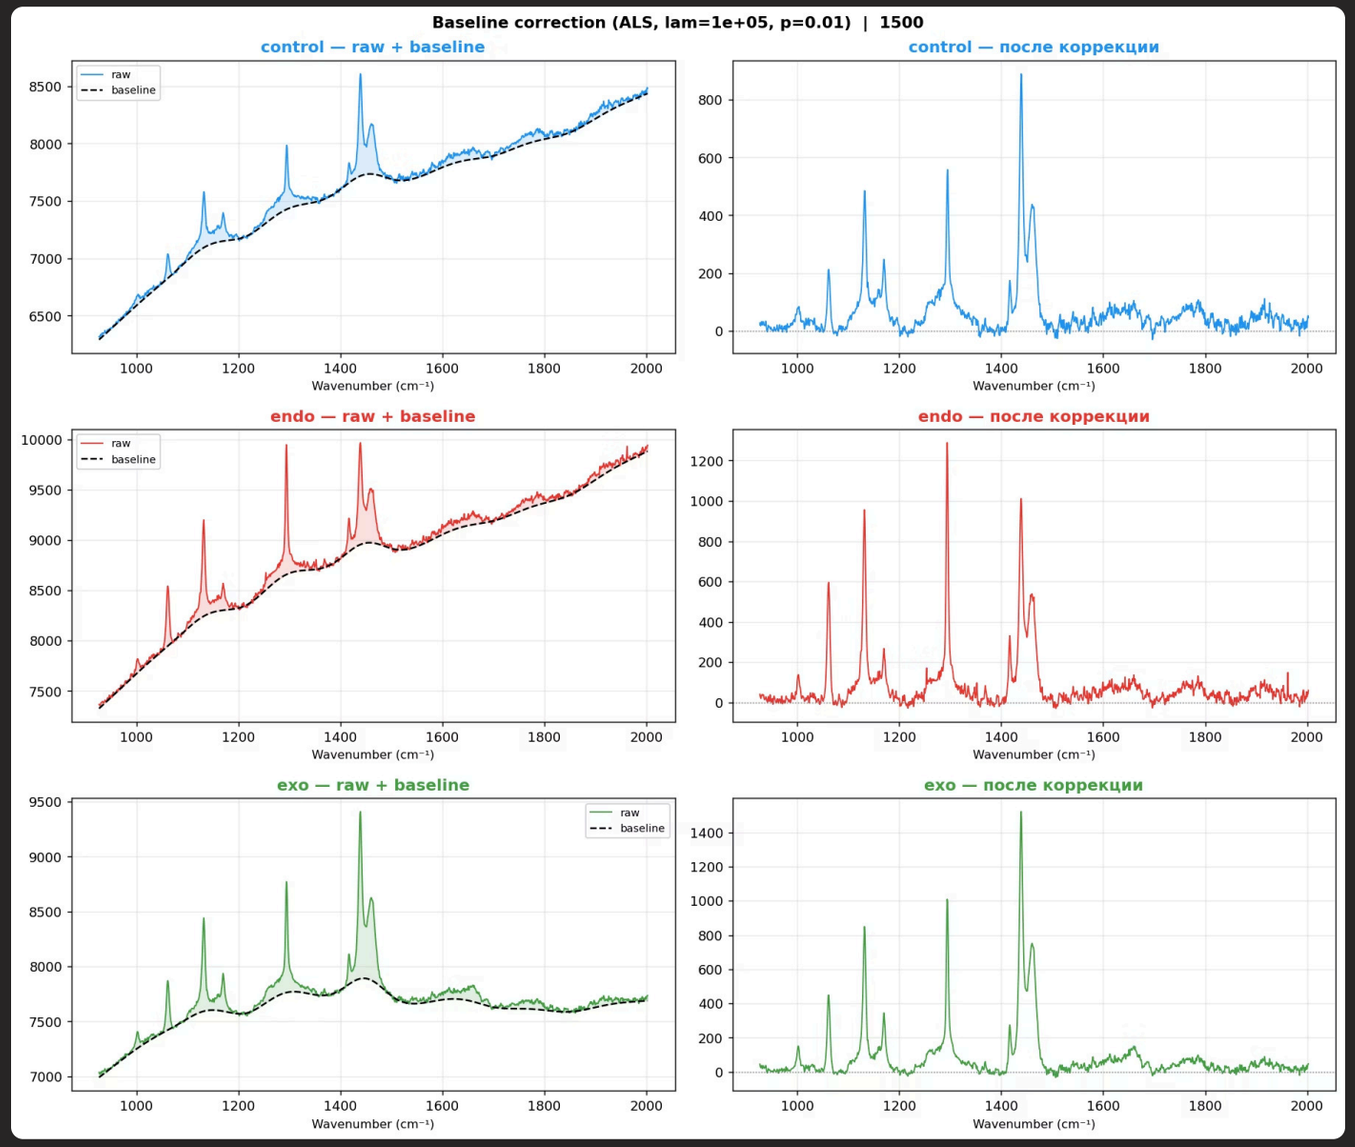


Made with GAMMA

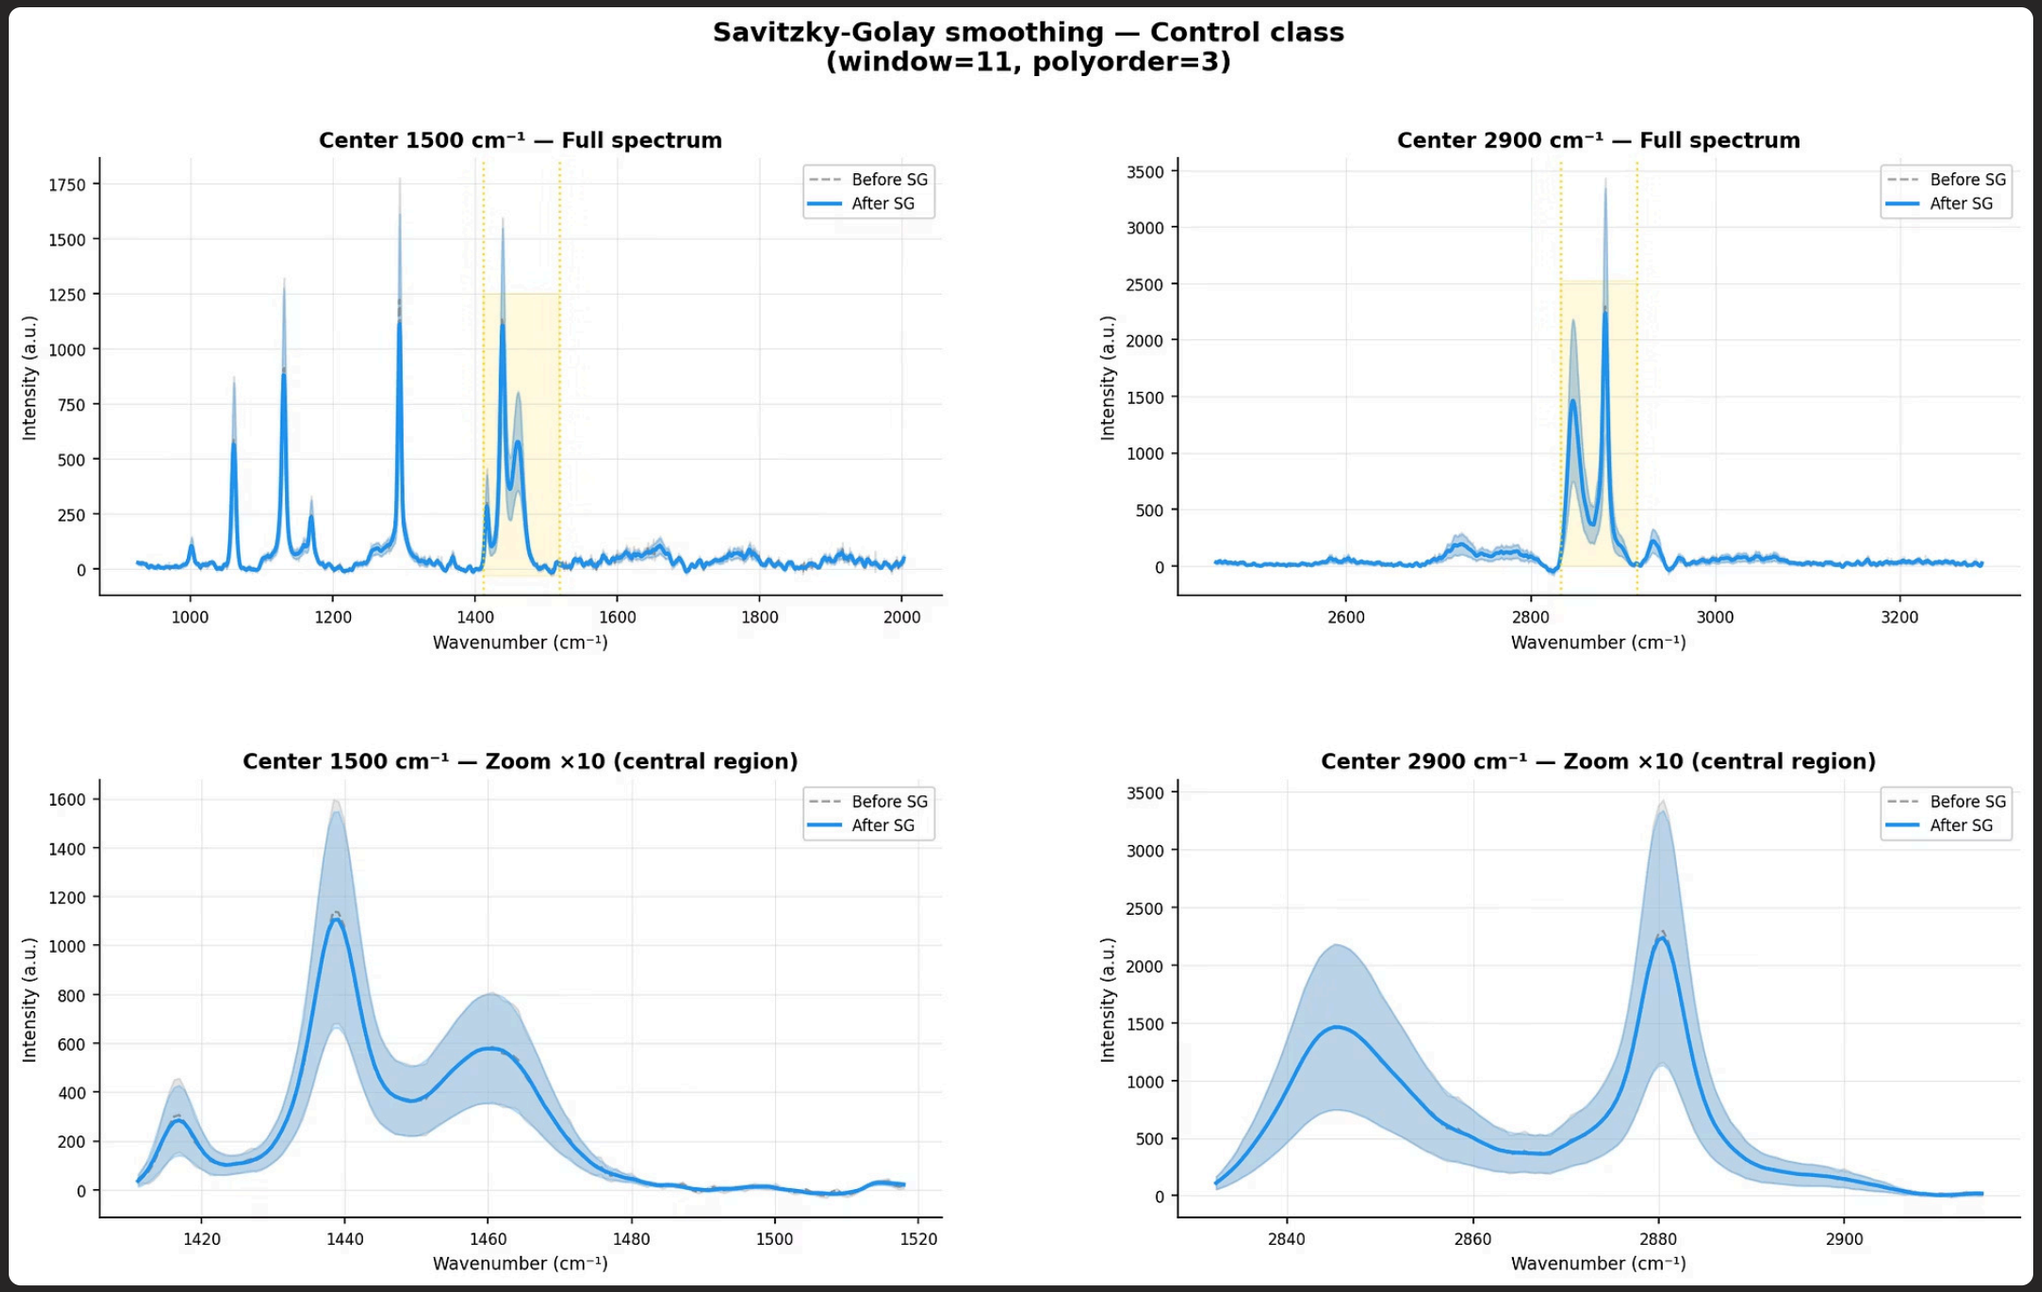


# Сглаживание

Made with GAMMA

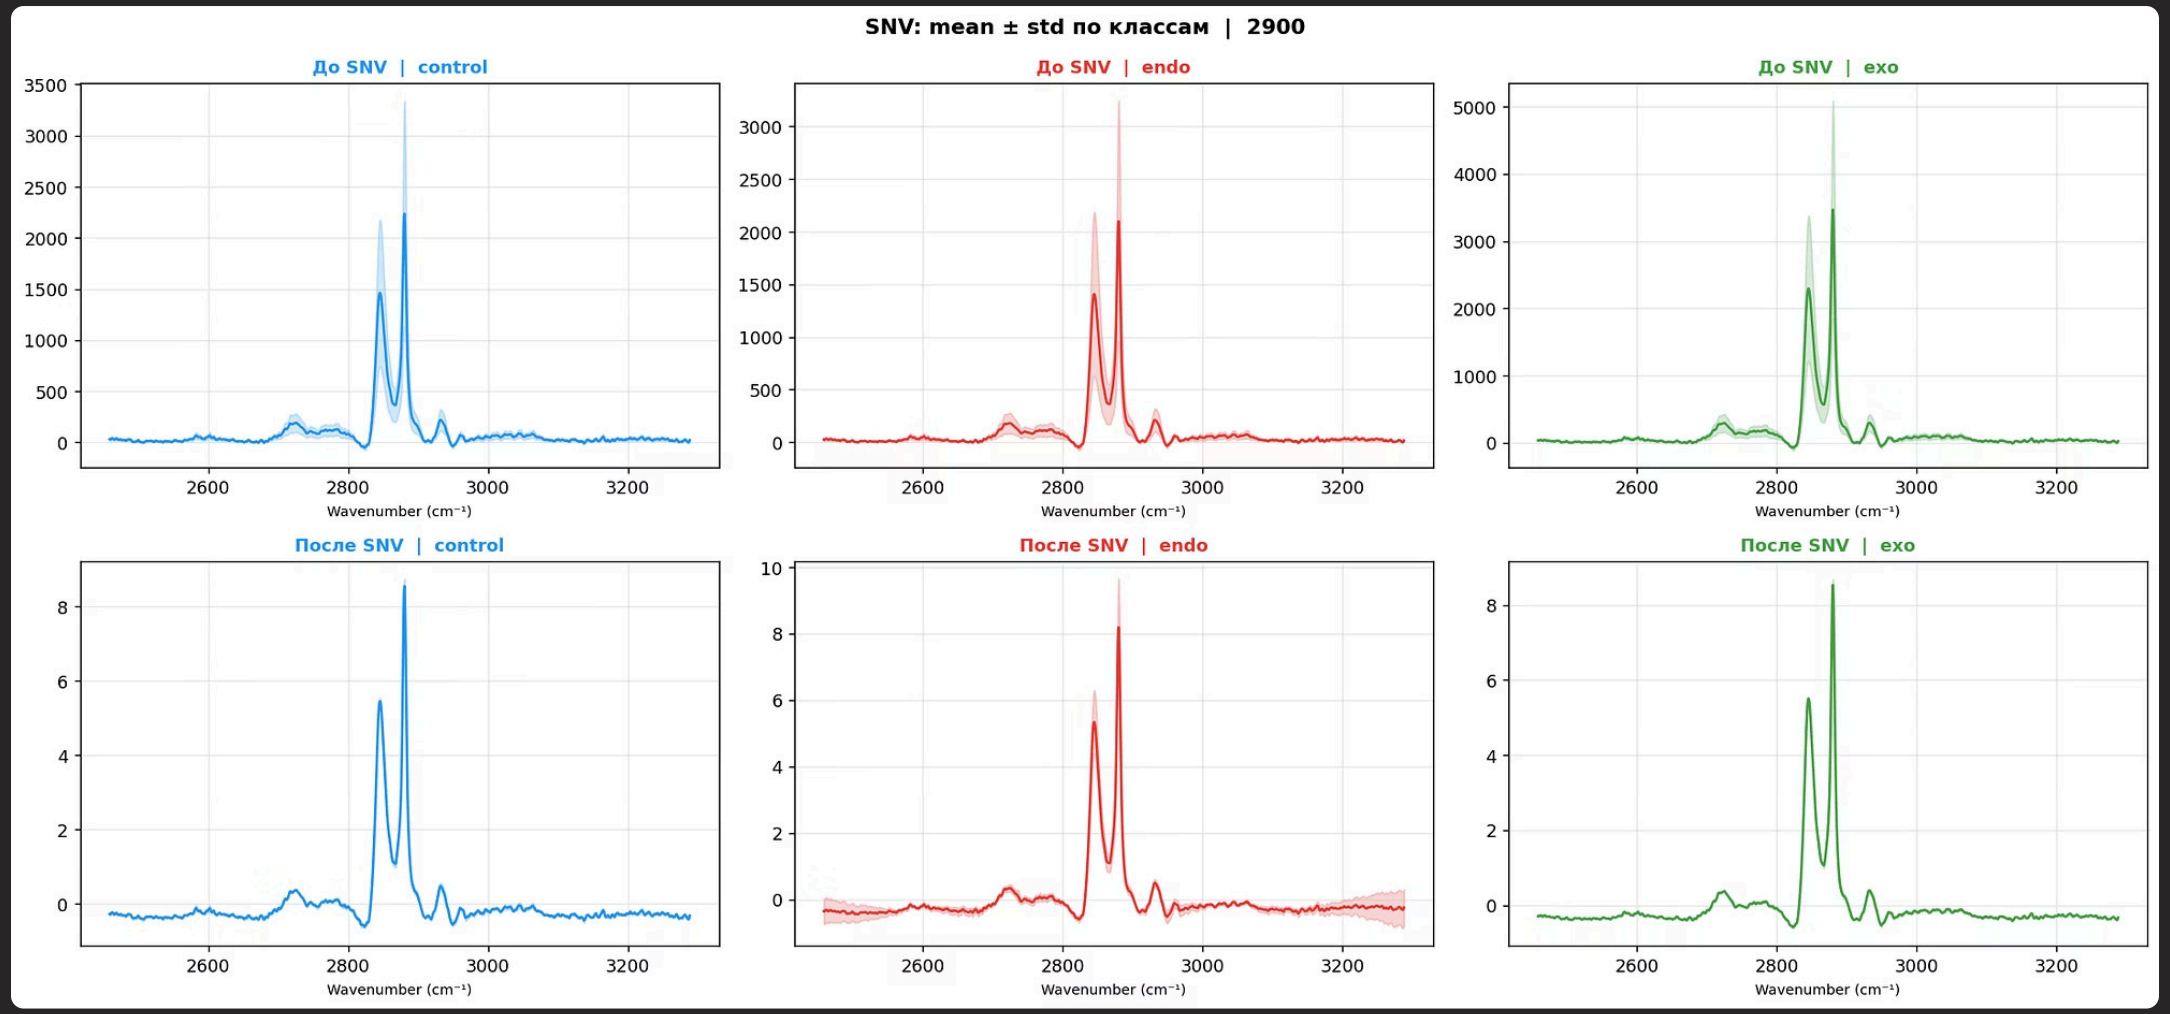


# Нормализация

Made with GAMMA

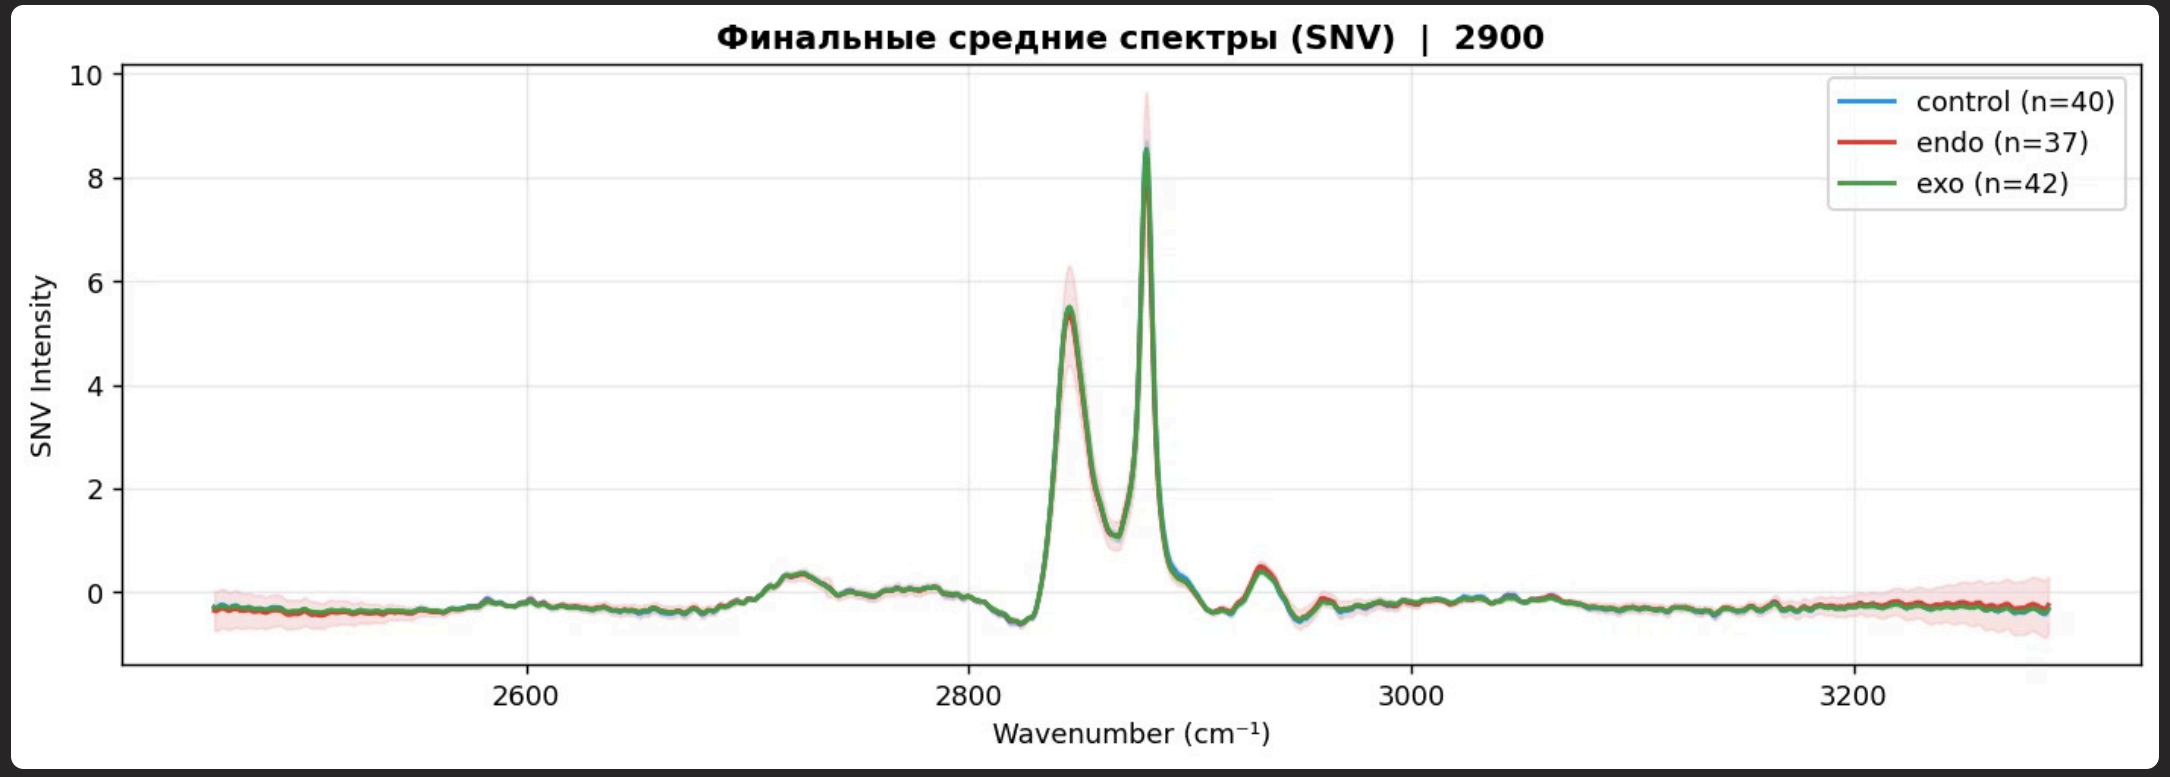


Made with GAMMA

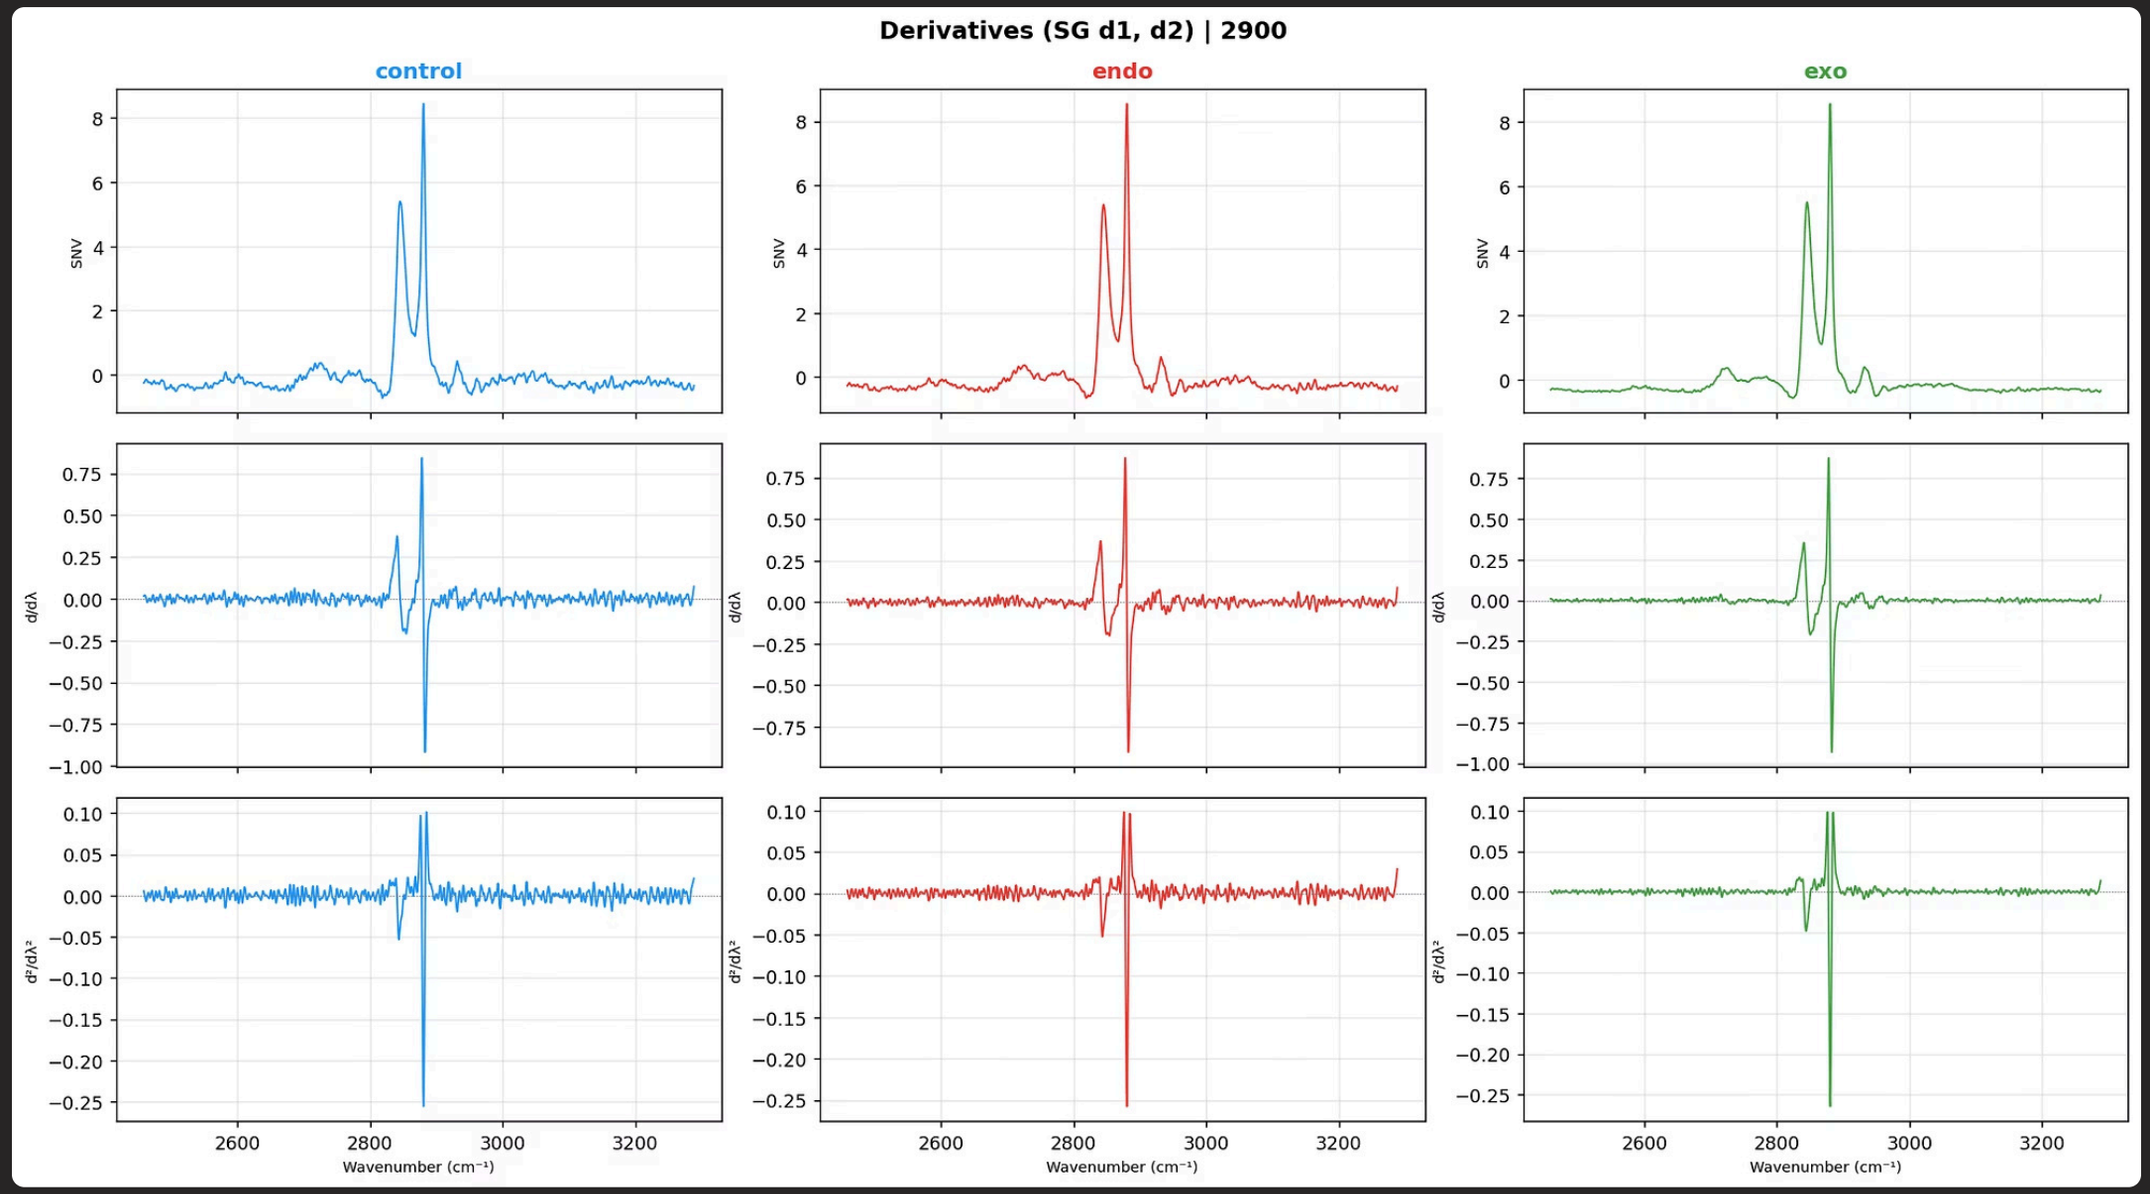


Made with GAMMA

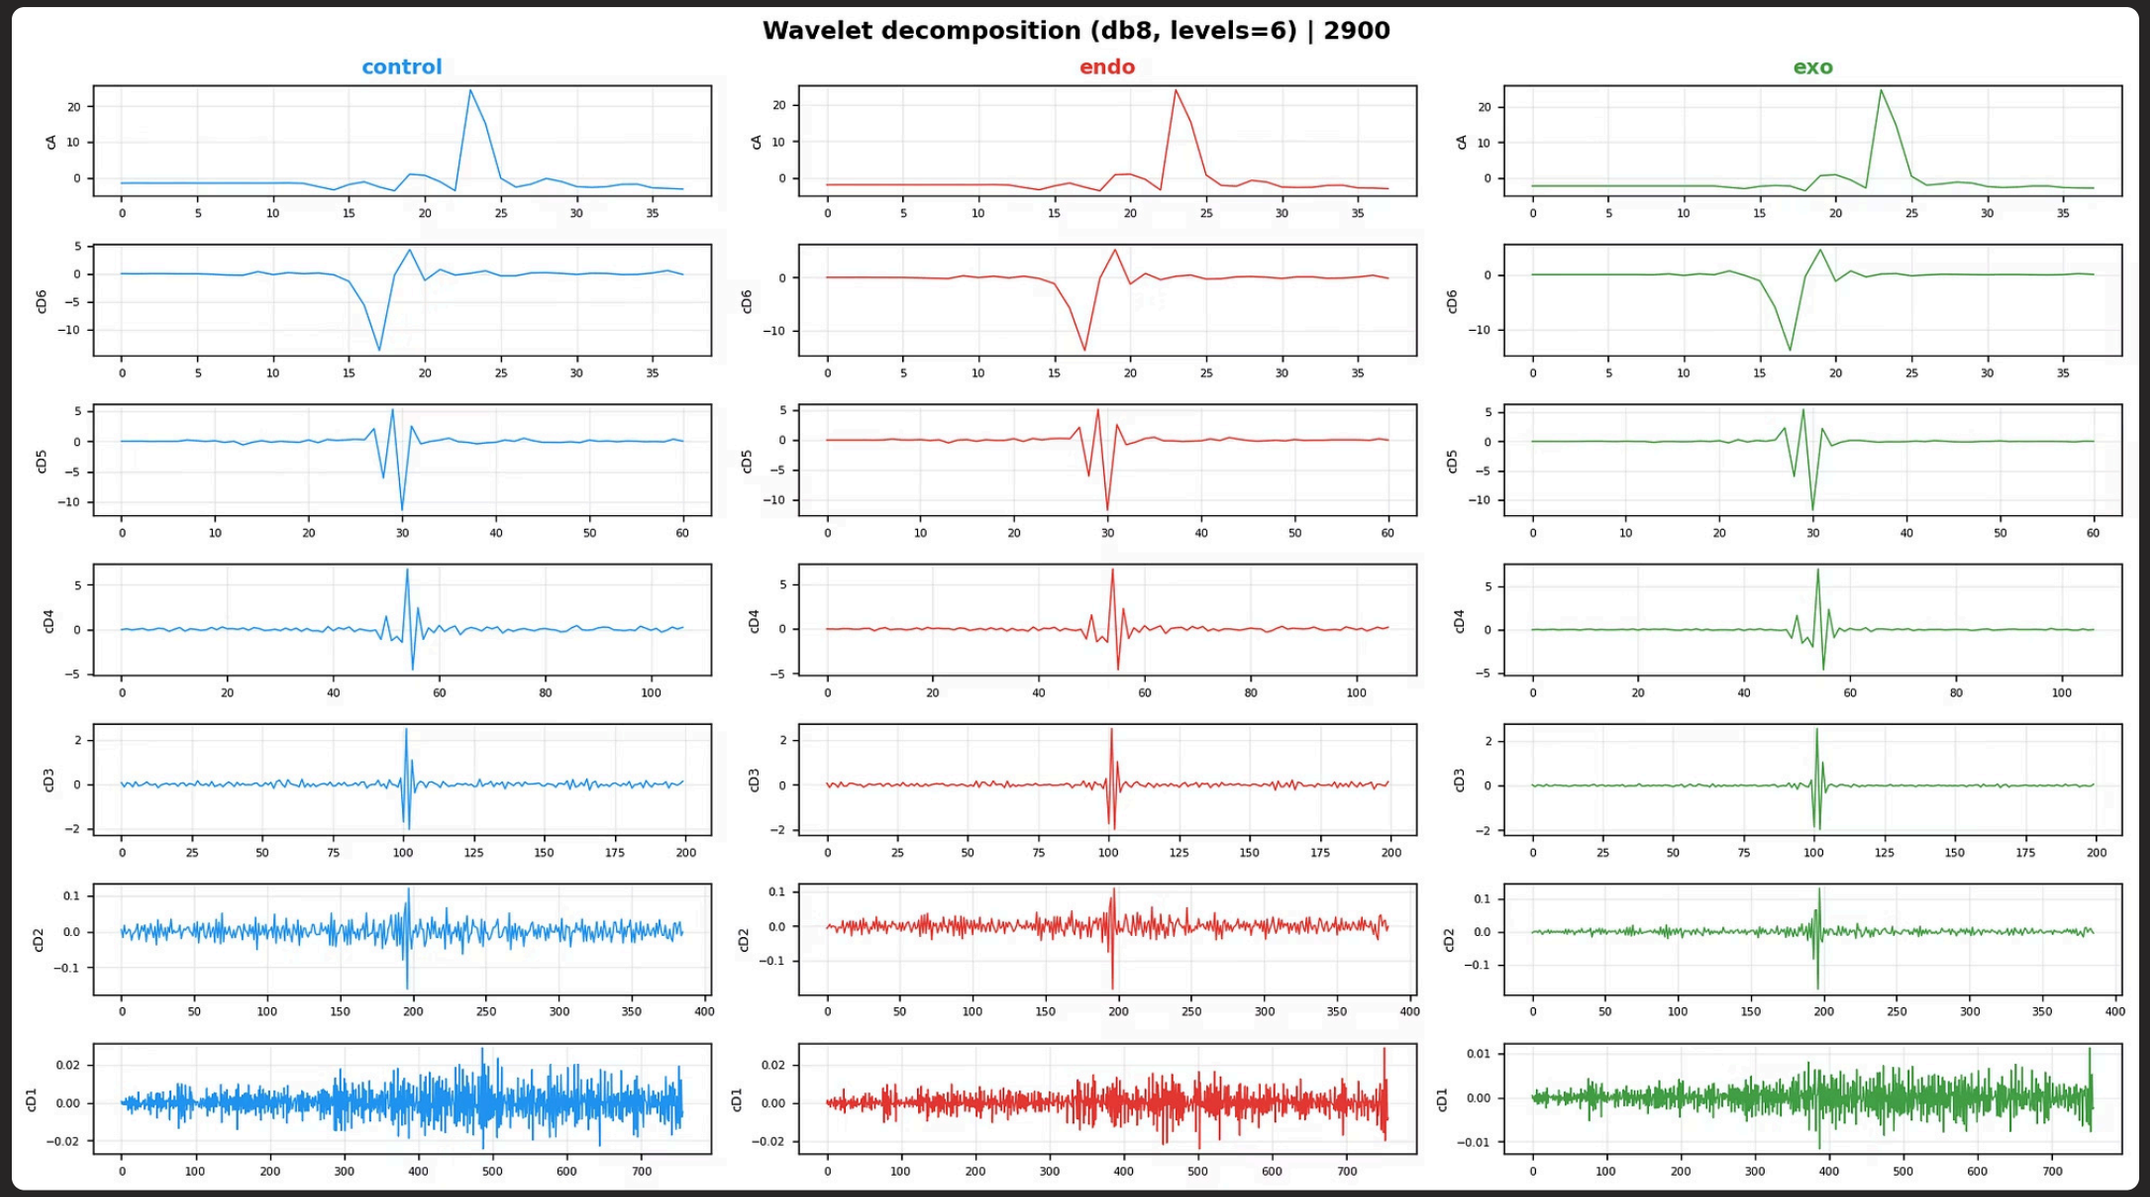


Made with GAMMA

# Стратегия LOAO-валидации

Для исключения биологической утечки данных мы используем *Leave-One-Animal-Out*: на каждом фолде все спектры одного животного тестируются на модели, обученной на остальных.

| Фолд | Животное в тесте | Карт в тесте |
|---|---|---|
| 1 | Животное №1 | 36 |
| 2 | Животное №2 | 33 |
| 3 | Животное №3 | 14 |
| 4 | Животное №4 | 33 |

Made with GAMMA

# Стекинг 21 модели

## Базовый уровень

Мы использовали 7 алгоритмов (XGBoost, LGBM, CatBoost, RF, Extra Trees, SVM, MLP) на 3 наборах признаков. Настройка проводилась через Optuna (50 итераций).

## Мета-уровень

OOF-вероятности подаются в мета-модель (LogReg). Оптимизация порогов решения $\hat{y} = \arg \max_c (p_c / \theta_c)$ позволяет максимизировать точность.

Made with GAMMA

| Класс | Precision | Recall | F1-score | Support |
|---|---|---|---|---|
| control | 0.76 | 0.78 | 0.77 | 40 |
| endo | 0.86 | 0.83 | 0.85 | 36 |
| exo | 0.76 | 0.76 | 0.76 | 42 |
| macro avg | 0.79 | 0.79 | 0.79 | 118 |

Made with GAMMA

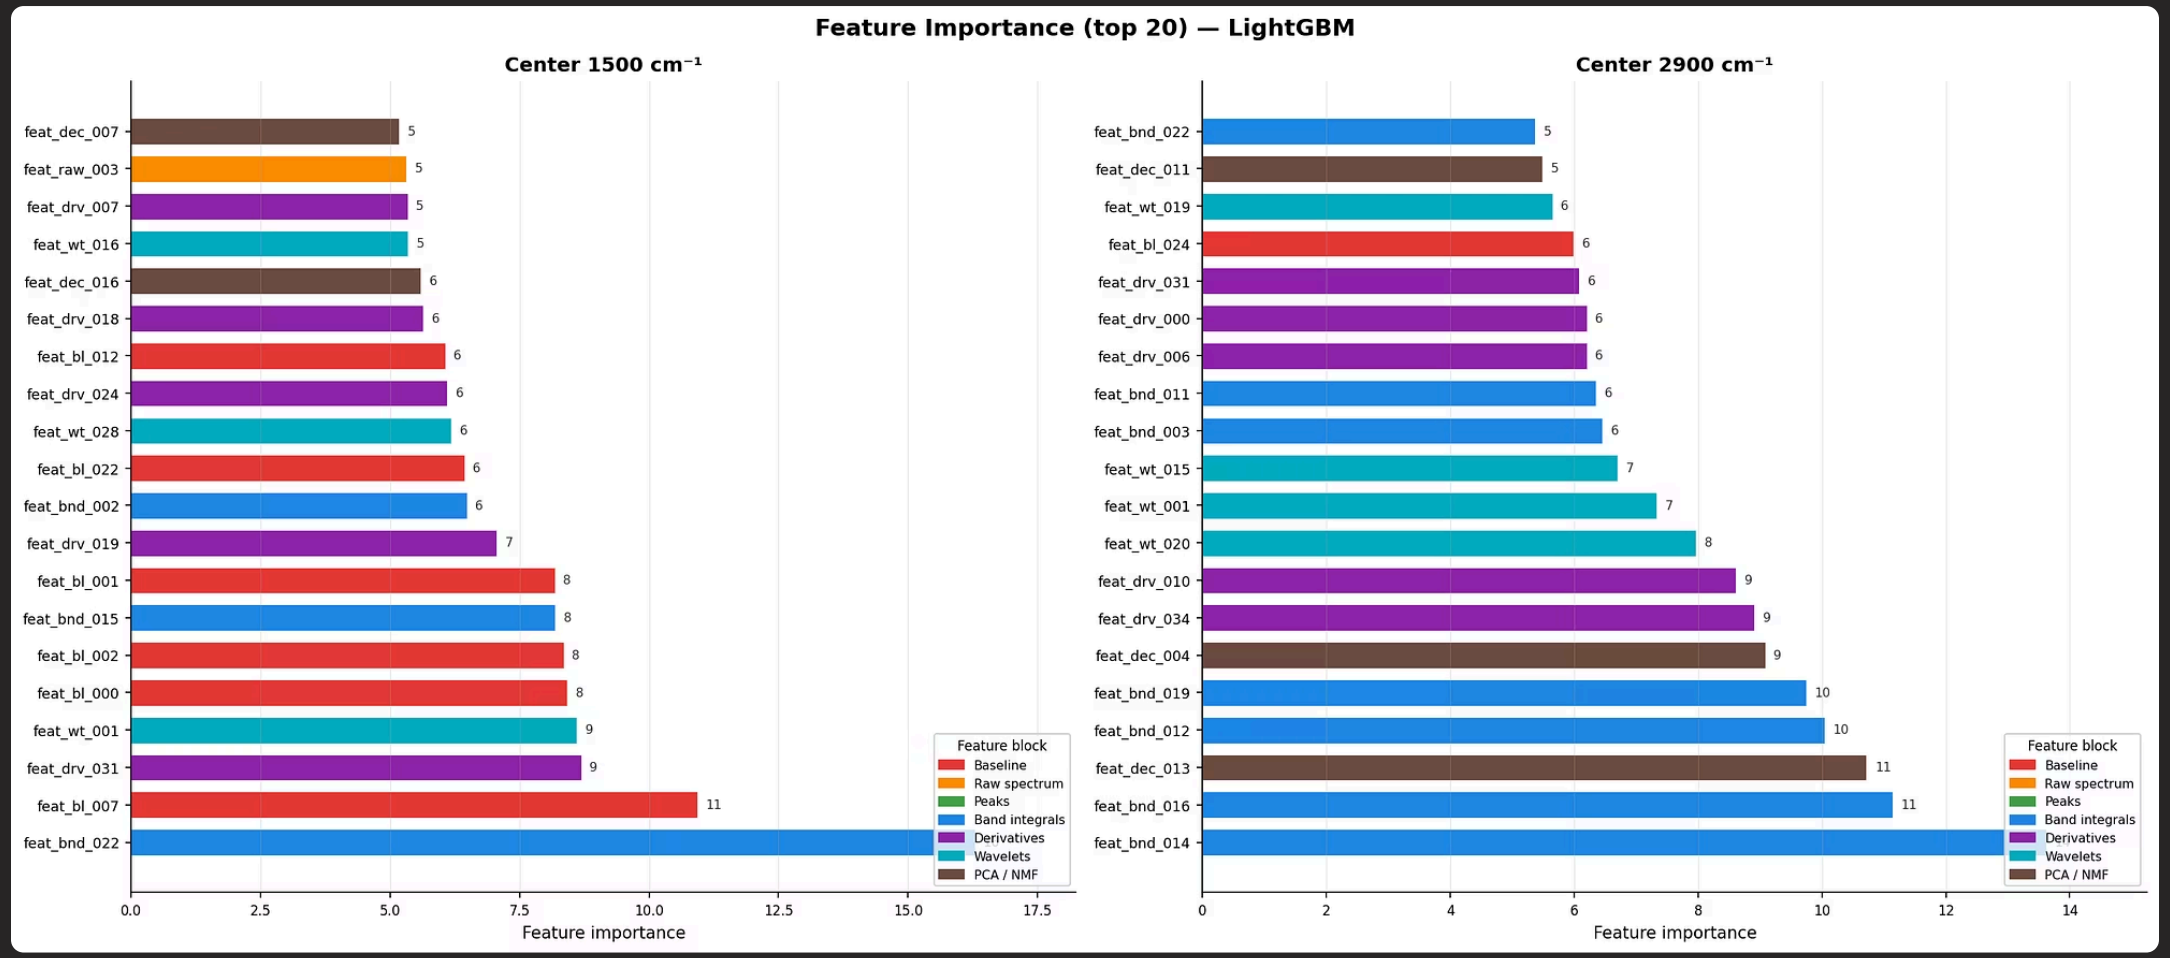


Made with GAMMA