Классификация рамановских спектров мозговой ткани методами машинного обучения

Gradient Island Team

7 марта 2026 г.

Аннотация

Разработана модель машинного обучения для классификации рамановских спектров мозговой ткани крыс по трём группам: контроль, эндогенная и экзогенная экспрессия HSP70. Применены предобработка (AsLS, Savitzky–Golay, SNV), многоуровневое извлечение признаков, LOAO-валидация и стекинг 21 базовой модели с оптимизацией порогов. Достигнут macro $F_1 = 0.7908$ (OOF).

1 Постановка задачи

Целью работы является разработка модели машинного обучения, которая по рамановскому спектру мозговой ткани крысы определяет экспериментальную группу животного: *контроль*, *эндогенная экспрессия HSP70* (endo) или *экзогенная экспрессия HSP70* (exo). Решаемая задача мотивирована необходимостью выявления спектральных маркеров, наиболее чувствительных к нейропротективным и стресс-индуцированным молекулярным изменениям в ткани мозга.

Рамановская спектроскопия позволяет неинвазивно регистрировать молекулярный состав ткани через характеристические полосы колебаний химических связей. Белок теплового шока HSP70 является ключевым шапероном клеточного стресс-ответа: его эндогенная индукция возникает в ответ на повреждение, тогда как экзогенное введение рассматривается как потенциальная нейропротективная стратегия. Спектральные различия между тремя группами ожидаются в диапазонах, связанных с белковой конформацией (амидные полосы), липидным составом мембран и нуклеиновыми кислотами.

1.1 Формальная постановка

Пусть имеется набор данных $\mathcal{D} = \{(\mathbf{x}_i,\, y_i)\}_{i=1}^{N}$, где $\mathbf{x}_i \in \mathbb{R}^p$ — вектор признаков, извлечённых из рамановского спектра i-й спектральной карты, а $y_i \in \{\text{control, endo, exo}\}$ — метка класса. Требуется построить классификатор $f\colon \mathbb{R}^p \to \{\text{control}, \text{endo}, \text{exo}\}$, максимизирующий макро-усреднённую F_1-меру:

$$F_1^{\text{macro}} = \frac{1}{3}\sum_{c\in\mathcal{C}} F_1^{(c)}, \qquad F_1^{(c)} = \frac{2\,\text{TP}_c}{2\,\text{TP}_c + \text{FP}_c + \text{FN}_c}. \tag{1}$$

1.2 Данные

Исходные данные представлены спектральными картами различных отделов мозга крыс, полученных методом конфокальной рамановской микроскопии. Спектры регистрировались в двух спектральных окнах:

- **Диапазон 1500 см$^{-1}$** (600–1800 см$^{-1}$) — «отпечаток пальца» (fingerprint region): белковые, нуклеиновые и липидные полосы поглощения.
- **Диапазон 2900 см$^{-1}$** (2800–3100 см$^{-1}$) — валентные колебания C–H: характеристика липидного состава мембран.

Суммарный объём: 118 спектральных карт на диапазон, 4 животных (по числу LOAO-фолдов), три класса (40 control, 36 endo, 42 exo). Исходный датафрейм содержит порядка 126 миллионов строк вида `(X, Y, Wave, Intensity, label, animal, center, brain, place)`.

2 Методология

2.1 Предобработка спектров

Усреднение и построение общей сетки. Для каждой спектральной карты (уникальная комбинация животного, отдела мозга и места измерения) точки одного пространственного положения (X, Y) усреднялись по интенсивности при одинаковом значении сдвига. Тем самым каждая карта редуцировалась к единому среднему спектру. Затем все спектры интерполировались на унифицированную сетку из 1500 равноотстоящих точек в диапазоне $[q_{2\%},\, q_{98\%}]$ по оси волновых чисел.

Коррекция флуоресцентного фона. Флуоресценция тканей создаёт широкую аддитивную базовую линию, маскирующую рамановский сигнал. Для её удаления применялся алгоритм AsLS (*Asymmetric Least Squares Smoothing*):

$$\hat{\mathbf{z}} = \arg\min_{\mathbf{z}} \Big[\mathbf{w}^\top (\mathbf{y} - \mathbf{z})^2 + \lambda \|\mathbf{D}^{(2)}\mathbf{z}\|^2 \Big], \tag{2}$$

где $\mathbf{D}^{(2)}$ — матрица вторых разностей, $\lambda = 10^5$ управляет гладкостью базовой линии, веса w_j итеративно обновляются: $w_j = p$ при $y_j > z_j$ и $w_j = 1 - p$ иначе ($p = 0.01$, число итераций 15). Скорректированный спектр: $\tilde{\mathbf{y}} = \mathbf{y} - \hat{\mathbf{z}}$.

Сглаживание. К скорректированным спектрам применялся фильтр Савицкого–Голая (*Savitzky-Golay*): ширина окна 11 точек, степень полинома 3. Фильтр сохраняет форму пиков, уменьшая высокочастотный шум.

Стандартное нормальное варьирование (SNV). Для устранения мультипликативных рассеивающих эффектов каждый спектр нормализовался по формуле:

$$x_j^{\text{snv}} = \frac{x_j - \bar{x}}{\sigma_x}, \tag{3}$$

где $\bar{x}$ и σ_x — среднее и стандартное отклонение интенсивностей данного спектра.

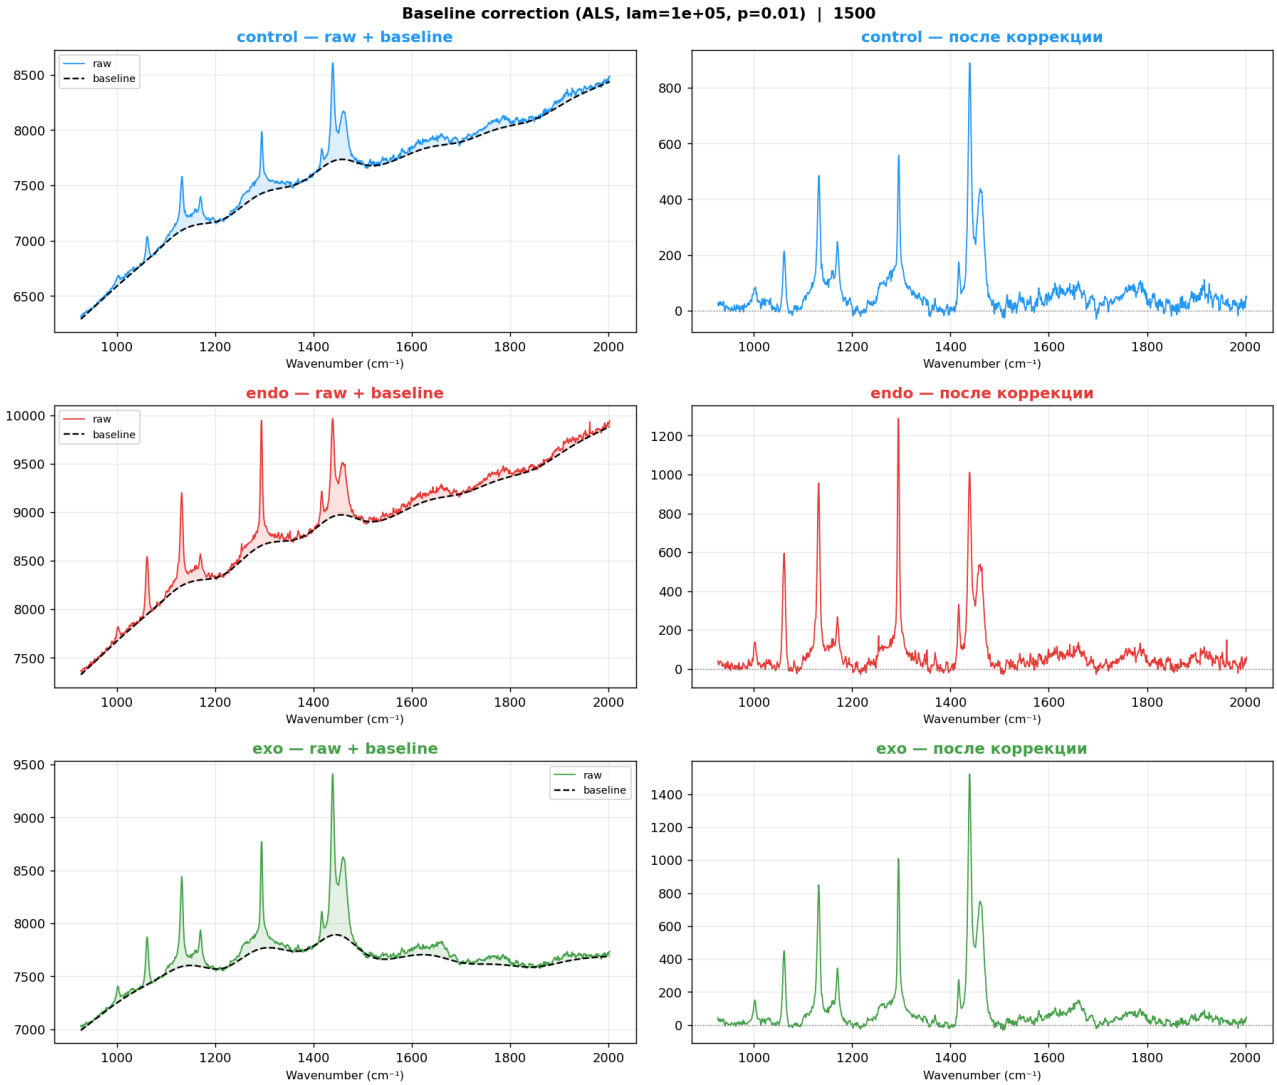

2.2 Извлечение признаков

Признаковое пространство формировалось из нескольких групп, каждая из которых кодирует различный аспект спектра.

Признаки биохимических полос. Для каждого из диагностически значимых диапазонов (табл. 1) вычислялись: площадь под кривой (численное интегрирование методом трапеций), максимальная и средняя интенсивность, положение главного пика, стандартное отклонение и коэффициент асимметрии. Дополнительно формировались попарные отношения площадей соседних полос.

Диапазон	Молекулярное отнесение	Позиция, см$^{-1}$
Fingerprint region (1500)		
	Фенилаланин	1000–1010
	Пролин	850–860
	Гидроксипролин	875–885
	Амид III (β-лист)	1230–1270
	Амид III (α-спираль)	1270–1310
	Деформация CH_2	1440–1470
	Амид II	1540–1560
	Амид I (α-спираль)	1650–1660
	Амид I (β-лист)	1670–1690
	Эфир липидов	1730–1760
	ДНК/РНК	780–800
	Тирозин	830–840
CH-region (2900)		
	CH_2 симметр. валентные	2845–2855
	CH_2 асимметр. валентные	2880–2900
	CH_3 валентные	2930–2960
	Олефиновые CH	3000–3030

Таблица 1: Биохимически значимые рамановские полосы.

Производные признаки. Первая и вторая производные SNV-спектра (метод Савицкого–Голая) характеризуют скорость и кривизну изменения сигнала. Для каждой производной вычислялись: среднее, стандартное отклонение, максимум абсолютного значения, суммарная энергия, число нулевых переходов, зональные энергии (8 равных сегментов).

Вейвлет-признаки. Дискретное вейвлет-преобразование (*Daubechies db8*, 5 уровней) разлагало спектр на поддиапазоны различных масштабов. Для каждого коэффициентного вектора извлекались: суммарная энергия, относительная энергия, среднее, стандартное отклонение и вейвлет-энтропия $H = -\sum_k p_k \ln p_k$, где $p_k = c_k^2 / \sum_j c_j^2$.

Зональные статистики. Спектр делился на 8 равных частей; для каждой зоны вычислялись среднее и стандартное отклонение интенсивности, отношения к первой зоне и разности между соседними зонами.

Снижение размерности (PCA и NMF). Из SNV-матрицы карт извлекались 20 главных компонент (PCA) и 15 неотрицательных компонент (NMF, предварительная Min-Max нормализация). Обе трансформации фиксировались при обучении и применялись без переобучения при инференсе.

После конкатенации всех блоков итоговое признаковое пространство составляет 284–328 признаков на диапазон.

Отбор признаков. Для каждого диапазона применялся LightGBM-ранкинг по важности типа *gain*: из полного набора отбиралось 120 признаков с наибольшим вкладом. Это позволяло снизить размерность почти без потери информативности.

2.3 Стратегия валидации: Leave-One-Animal-Out

Принципиальной проблемой оценки модели на биологических данных является утечка информации между образцами одного животного: спектры с разных участков мозга одной крысы биологически зависимы. Использование обычного k-Folds Cross Validation приводит к завышенным оценкам.

Для корректной оценки обобщающей способности применялась схема Leave-One-Animal-Out (LOAO): на каждой итерации все карты одного животного ($n = 4$ животных) изымались в тест, остальные использовались для обучения (табл. 2). Все метрики (включая настройку гиперпараметров Optuna) вычислялись исключительно на out-of-fold предсказаниях.

Фолд	**Животное в тесте**	**Карт в тесте**
1	1	36
2	2	18
3	3	31
4	4	33

Таблица 2: Структура LOAO-фолдов.

2.4 Базовые модели и подбор гиперпараметров

Обучались семь базовых классификаторов: XGBoost, LightGBM, CatBoost, Random Forest, Extra Trees, SVM (RBF/poly), MLP. Перед подачей в каждую модель признаки масштабировались `StandardScaler`.

Гиперпараметры подбирались методом байесовской оптимизации (библиотека Optuna, семплер TPE, 50 испытаний на модель). Целевой функцией служил macro F_1 по LOAO-OOF предсказаниям.

Каждая модель обучалась независимо на трёх наборах признаков: диапазон 1500, диапазон 2900 и *joint* (конкатенация обоих диапазонов с дополнительными межканальными признаками). Итого обучалось $7 \times 3 = 21$ базовая модель.

2.5 Ансамблирование: стекинг с оптимизацией порогов

OOF-вероятности всех 21 модели конкатенировались в мета-матрицу $\mathbf{M} \in \mathbb{R}^{N \times (21 \cdot 3)}$ и подавались на вход мета-классификатору. Рассматривались следующие стратегии:

1. **Soft Voting** — взвешенное среднее вероятностей, где веса пропорциональны OOF F_1 каждой модели.

2. **Geometric Mean** — геометрическое среднее вероятностей, сглаживающее эффект уверенных ошибочных предсказаний.
3. **Rank Averaging** — усреднение ранговых позиций по каждому классу.
4. **Stacking** — мета-классификатор (Logistic Regression), обученный на $\mathbf{M}$ с 5-кратной стратифицированной перекрёстной проверкой.
5. **Best + Threshold** — лучшая стратегия с дополнительной покоординатной оптимизацией порогов решения: $\hat{y} = \arg\max_c(p_c/\theta_c)$, где θ_c подбирается сеточным поиском по F_1^{macro}.

Итоговые OOF-метрики всех стратегий представлены в табл. 3.

Стратегия	**Macro F1**	**Accuracy**	**F1 control**	**F1 endo**	**F1 exo**
Soft Voting	0.494	0.500	0.490	0.390	0.600
Geometric Mean	0.504	—	—	—	—
Rank Averaging	0.486	—	—	—	—
Stacking (LR)	0.764	0.763	0.750	0.810	0.730
Best + Threshold	**0.791**	**0.788**	**0.770**	**0.850**	**0.760**

Таблица 3: Сравнение стратегий ансамблирования (LOAO-OOF).

3 Результаты

3.1 Итоговые метрики классификации

Лучший результат достигнут стратегией «Stacking + Threshold»: macro $F_1 = 0.791$, accuracy $= 0.788$ на LOAO-OOF. Детальный отчёт классификации представлен в табл. 4.

Класс	**Precision**	**Recall**	**F1-score**	**Support**
control	0.76	0.78	0.77	40
endo	0.86	0.83	0.85	36
exo	0.76	0.76	0.76	42
macro avg	0.79	0.79	0.79	118

Таблица 4: Отчёт классификации (LOAO-OOF, Best+Threshold).

3.2 Анализ значимости признаков

Наиболее высокий gain-вклад в обоих диапазонах вносят:

- **1500 см$^{-1}$:** отношения интегралов амид I / амид III (маркер вторичной структуры белка), площадь полосы эфиров липидов (1730–1760 см$^{-1}$), вейвлет-энергии среднего масштаба (cD_3, cD_4).
- **2900 см$^{-1}$:** отношение CH_2/CH_3 (степень ненасыщенности жирных кислот), площадь олефиновой полосы (3000–3030 см$^{-1}$), PCA-компонента 1 (доля объяснённой дисперсии $\approx 40\%$).

Это согласуется с биологическими ожиданиями: экспрессия HSP70 сопровождается реорганизацией белков и изменениями в мембранных липидах нейронов.

4 Заключение

В работе разработан полный пайплайн классификации рамановских спектров мозговой ткани крысы по трём экспериментальным группам. Ключевые результаты:

1. Разработана процедура предобработки, включающая коррекцию флуоресцентного фона (ALS), сглаживание (SG) и SNV-нормализацию, обеспечивающая воспроизводимое сравнение спектров разных карт.
2. Сформировано многоуровневое признаковое пространство из биохимических полос, производных, вейвлет-коэффициентов и компонент снижения размерности.
3. Применена схема LOAO-CV, исключающая утечку биологической информации между животными.
4. Обучен ансамбль из 21 базовой модели (7 алгоритмов $\times$ 3 набора признаков) с байесовской настройкой гиперпараметров.
5. Итоговый macro $F_1 = 0.791$ достигнут через стекинговый мета-классификатор с оптимизацией порогов решения.

Наиболее информативными оказались признаки амидных полос (вторичная структура белка) и соотношение CH_2/CH_3 (ненасыщенность мембранных липидов).