Классификация рамановских спектров мозговой ткани методами машинного обучения

Команда: Gradient Island

Задача: Nuclear It Hack

Метод: Ансамблевое машинное обучение со стекингом

Метрика: Macro F1-score

Результат: Macro F1 = 0.7908 (OOF LOAO-CV)

7 марта 2026 г.

Содержание

1 Постановка задачи **2**

1.1 Формальная постановка 2

1.2 Данные 2

2 Методология **3**

2.1 Предобработка спектров 3

2.2 Извлечение признаков 4

2.3 Стратегия валидации: Leave-One-Animal-Out 6

2.4 Базовые модели и подбор гиперпараметров 6

2.5 Ансамблирование: стекинг с оптимизацией порогов 7

3 Результаты **8**

3.1 Итоговые метрики классификации 8

3.2 Анализ значимости признаков 9

3.3 Пространство признаков: визуализация PCA 10

4 Обсуждение **10**

5 Заключение **10**

1 Постановка задачи

Целью работы является разработка модели машинного обучения, которая по рамановскому спектру мозговой ткани крысы определяет экспериментальную группу животного: *контроль*, *эндогенная экспрессия HSP70* (endo) или *экзогенная экспрессия HSP70* (exo). Решаемая задача мотивирована необходимостью выявления спектральных маркеров, наиболее чувствительных к нейропротективным и стресс-индуцированным молекулярным изменениям в ткани мозга.

Рамановская спектроскопия позволяет неинвазивно регистрировать молекулярный состав ткани через характеристические полосы колебаний химических связей. Белок теплового шока HSP70 является ключевым шапероном клеточного стресс-ответа: его эндогенная индукция возникает в ответ на повреждение, тогда как экзогенное введение рассматривается как потенциальная нейропротективная стратегия. Спектральные различия между тремя группами ожидаются в диапазонах, связанных с белковой конформацией (амидные полосы), липидным составом мембран и нуклеиновыми кислотами.

1.1 Формальная постановка

Пусть имеется набор данных $\mathcal{D} = \{(\mathbf{x}_i,\, y_i)\}_{i=1}^{N}$, где $\mathbf{x}_i \in \mathbb{R}^p$ — вектор признаков, извлечённых из рамановского спектра i-й спектральной карты, а $y_i \in \{\text{control, endo, exo}\}$ — метка класса. Требуется построить классификатор $f\colon \mathbb{R}^p \to \{\text{control}, \text{endo}, \text{exo}\}$, максимизирующий макро-усреднённую F_1-меру:

$$F_1^{\text{macro}} = \frac{1}{3} \sum_{c \in \mathcal{C}} F_1^{(c)}, \qquad F_1^{(c)} = \frac{2\,\text{TP}_c}{2\,\text{TP}_c + \text{FP}_c + \text{FN}_c}. \tag{1}$$

1.2 Данные

Исходные данные представлены спектральными картами различных отделов мозга крыс, полученных методом конфокальной рамановской микроскопии. Спектры регистрировались в двух спектральных окнах:

- **Диапазон 1500 см$^{-1}$** (600–1800 см$^{-1}$) — «отпечаток пальца» (fingerprint region): белковые, нуклеиновые и липидные полосы поглощения.
- **Диапазон 2900 см$^{-1}$** (2800–3100 см$^{-1}$) — валентные колебания C–H: характеристика липидного состава мембран.

Суммарный объём: 118–119 спектральных карт на диапазон, 4 животных (по числу LOAO-фолдов), три класса (40 control, 36–37 endo, 42 exo). Исходный датафрейм содержит порядка 126 миллионов строк вида `(X, Y, Wave, Intensity, label, animal, center, brain, place)`.

2 Методология

Общая схема пайплайна представлена на рис. 1.

[Место для схемы пайплайна]

Рис. 1: Общая архитектура пайплайна обработки и классификации.

2.1 Предобработка спектров

Усреднение и построение общей сетки. Для каждой спектральной карты (уникальная комбинация животного, отдела мозга и места измерения) точки одного пространственного положения (X, Y) усреднялись по интенсивности при одинаковом значении сдвига. Тем самым каждая карта редуцировалась к единому среднему спектру. Затем все спектры интерполировались на унифицированную сетку из 1500 равноотстоящих точек в диапазоне $[q_{2\%},\, q_{98\%}]$ по оси волновых чисел.

Коррекция флуоресцентного фона. Флуоресценция тканей создаёт широкую аддитивную базовую линию, маскирующую рамановский сигнал. Для её удаления применялся алгоритм AsLS (*Asymmetric Least Squares Smoothing*):

$$\hat{\mathbf{z}} = \arg\min_{\mathbf{z}} \Big[\mathbf{w}^\top (\mathbf{y} - \mathbf{z})^2 + \lambda \|\mathbf{D}^{(2)}\mathbf{z}\|^2 \Big], \tag{2}$$

где $\mathbf{D}^{(2)}$ — матрица вторых разностей, $\lambda = 10^5$ управляет гладкостью базовой линии, веса w_j итеративно обновляются: $w_j = p$ при $y_j > z_j$ и $w_j = 1 - p$ иначе ($p = 0.01$, число итераций 15). Скорректированный спектр: $\tilde{\mathbf{y}} = \mathbf{y} - \hat{\mathbf{z}}$.

Сглаживание. К скорректированным спектрам применялся фильтр Савицкого–Голая (*Savitzky-Golay*): ширина окна 11 точек, степень полинома 3. Данный фильтр сохраняет форму пиков, уменьшая высокочастотный шум.

Стандартное нормальное варьирование (SNV). Для устранения мультипликативных рассеивающих эффектов каждый спектр нормализовался по формуле:

$$x_j^{\mathrm{snv}} = \frac{x_j - \bar{x}}{\sigma_x}, \tag{3}$$

где $\bar{x}$ и σ_x — среднее и стандартное отклонение интенсивностей данного спектра. Результат каждого шага предобработки иллюстрирует рис. 2.

[Место для графиков предобработки спектра: исходный → коррекция базовой линии → сглаживание → SNV]

Рис. 2: Последовательные шаги предобработки типичного спектра. Сверху вниз: исходный сигнал с базовой линией ALS, спектр после коррекции, после сглаживания SG, после SNV-нормализации.

2.2 Извлечение признаков

Признаковое пространство формировалось из нескольких групп, каждая из которых кодирует различный аспект спектра.

Признаки биохимических полос. Для каждого из диагностически значимых диапазонов (табл. 1) вычислялись: площадь под кривой (численное интегрирование методом трапеций), максимальная и средняя интенсивность, положение главного пика, стандартное отклонение и коэффициент асимметрии. Дополнительно формировались попарные отношения площадей соседних полос.

Таблица 1: Биохимически значимые рамановские полосы.

Диапазон	**Молекулярное отнесение**	**Позиция, см$^{-1}$**
Fingerprint region (1500)		
	Фенилаланин	1000–1010
	Пролин	850–860
	Гидроксипролин	875–885
	Амид III (β-лист)	1230–1270
	Амид III (α-спираль)	1270–1310
	Деформация CH_2	1440–1470
	Амид II	1540–1560
	Амид I (α-спираль)	1650–1660
	Амид I (β-лист)	1670–1690
	Эфир липидов	1730–1760
	ДНК/РНК	780–800
	Тирозин	830–840
CH-region (2900)		
	CH_2 симметр. валентные	2845–2855
	CH_2 асимметр. валентные	2880–2900
	CH_3 валентные	2930–2960
	Олефиновые CH	3000–3030

Производные признаки. Первая и вторая производные SNV-спектра (метод Савицкого–Голая) характеризуют скорость и кривизну изменения сигнала. Для каждой производной вычислялись: среднее, стандартное отклонение, максимум абсолютного значения, суммарная энергия, число нулевых переходов, зональные энергии (8 равных сегментов).

Вейвлет-признаки. Дискретное вейвлет-преобразование (*Daubechies db8*, 5 уровней) разлагало спектр на поддиапазоны различных масштабов. Для каждого коэффициентного вектора извлекались: суммарная энергия, относительная энергия, среднее, стандартное отклонение и вейвлет-энтропия $H = -\sum_k p_k \ln p_k$, где $p_k = c_k^2 / \sum_j c_j^2$.

Зональные статистики. Спектр делился на 8 равных частей; для каждой зоны вычислялись среднее и стандартное отклонение интенсивности, отношения к первой зоне и разности между соседними зонами.

Снижение размерности (PCA и NMF). Из SNV-матрицы карт извлекались 20 главных компонент (PCA) и 15 неотрицательных компонент (NMF, предварительная Min-Max нормализация). Обе трансформации фиксировались при обучении и применялись без переобучения при инференсе.

После конкатенации всех блоков итоговое признаковое пространство составляет 284–328 признаков на диапазон.

Отбор признаков. Для каждого диапазона применялся LightGBM-ранкинг по важности типа *gain*: из полного набора отбиралось 120 признаков с наибольшим вкладом. Это позволяло снизить размерность без потери информативности (рис. 3).

[Место для графика важности признаков по gain (top-30 для каждого из диапазонов 1500 и 2900)]

Рис. 3: Топ-30 признаков по gain-важности LightGBM для диапазонов 1500 см$^{-1}$ (слева) и 2900 см$^{-1}$ (справа).

2.3 Стратегия валидации: Leave-One-Animal-Out

Принципиальной проблемой оценки модели на биологических данных является утечка информации между образцами одного животного: спектры с разных участков мозга одной крысы биологически зависимы. Использование обычной k-кратной перекрёстной проверки приводит к завышенным оценкам.

Для корректной оценки обобщающей способности применялась схема **Leave-One-Animal-Out (LOAO)**: на каждой итерации все карты одного животного ($n = 4$ животных) изымались в тест, остальные использовались для обучения (табл. 2). Все метрики (включая настройку гиперпараметров Optuna) вычислялись исключительно на out-of-fold предсказаниях.

Таблица 2: Структура LOAO-фолдов.

Фолд	**Животное в тесте**	**Карт в тесте**
1	1	36
2	2	18
3	3	31
4	4	33

2.4 Базовые модели и подбор гиперпараметров

Обучались семь базовых классификаторов: XGBoost, LightGBM, CatBoost, Random Forest, Extra Trees, SVM (RBF/poly), MLP. Перед подачей в каждую модель признаки

масштабировались `StandardScaler`.

Гиперпараметры подбирались методом байесовской оптимизации (библиотека Optuna, семплер TPE, 50 испытаний на модель). Целевой функцией служил macro F_1 по LOAO-OOF предсказаниям.

Каждая модель обучалась независимо на трёх наборах признаков: диапазон 1500, диапазон 2900 и *joint* (конкатенация обоих диапазонов с дополнительными межканальными признаками). Итого обучалось $7 \times 3 = 21$ базовая модель.

Результаты базовых моделей приведены на рис. 4.

[Место для столбчатой диаграммы macro F1 (OOF) всех 21 базовой модели]

Рис. 4: Macro F1 (LOAO-OOF) для каждой из 21 базовой модели, сгруппированных по диапазону.

2.5 Ансамблирование: стекинг с оптимизацией порогов

OOF-вероятности всех 21 модели конкатенировались в мета-матрицу $\mathbf{M} \in \mathbb{R}^{N \times (21 \cdot 3)}$ и подавались на вход мета-классификатору. Рассматривались следующие стратегии:

1. **Soft Voting** — взвешенное среднее вероятностей, где веса пропорциональны OOF F_1 каждой модели.
2. **Geometric Mean** — геометрическое среднее вероятностей, сглаживающее эффект уверенных ошибочных предсказаний.
3. **Rank Averaging** — усреднение ранговых позиций по каждому классу.
4. **Stacking** — мета-классификатор (Logistic Regression), обученный на $\mathbf{M}$ с 5-кратной стратифицированной перекрёстной проверкой.
5. **Best + Threshold** — лучшая стратегия с дополнительной покоординатной оптимизацией порогов решения: $\hat{y} = \arg\max_c(p_c/\theta_c)$, где θ_c подбирается сеточным поиском по F_1^{macro}.

Итоговые OOF-метрики всех стратегий представлены в табл. 3.

Таблица 3: Сравнение стратегий ансамблирования (LOAO-OOF).

Стратегия	**Macro F1**	**Accuracy**	**F1 control**	**F1 endo**
Soft Voting	0.494	0.500	0.490	0.390
Geometric Mean	0.504	—	—	—
Rank Averaging	0.486	—	—	—
Stacking (LR)	0.764	0.763	0.750	0.810
Best + Threshold	**0.791**	**0.788**	**0.770**	**0.850**

3 Результаты

3.1 Итоговые метрики классификации

Лучший результат достигнут стратегией «Stacking + Threshold»: macro $F_1 = 0.791$, accuracy $= 0.788$ на LOAO-OOF. Детальный отчёт классификации представлен в табл. 4.

Таблица 4: Отчёт классификации (LOAO-OOF, Best+Threshold).

Класс	**Precision**	**Recall**	**F1-score**	**Support**
control	0.76	0.78	0.77	40
endo	0.86	0.83	0.85	36
exo	0.76	0.76	0.76	42
macro avg	0.79	0.79	0.79	118

Матрицы ошибок для всех стратегий приведены на рис. 5.

[Место для матриц ошибок (confusion matrices) по пяти стратегиям ансамблирования]

Рис. 5: Матрицы ошибок LOAO-OOF для пяти стратегий ансамблирования. Слева направо: Soft Voting, Geometric Mean, Rank Averaging, Stacking, Best+Threshold.

3.2 Анализ значимости признаков

Наиболее высокий gain-вклад в обоих диапазонах вносят:

- **1500 см$^{-1}$:** отношения интегралов амид I / амид III (маркер вторичной структуры белка), площадь полосы эфиров липидов (1730–1760 см$^{-1}$), вейвлет-энергии среднего масштаба (cD_3, cD_4).
- **2900 см$^{-1}$:** отношение CH_2/CH_3 (степень ненасыщенности жирных кислот), площадь олефиновой полосы (3000–3030 см$^{-1}$), PCA-компонента 1 (доля объяснённой дисперсии $\approx 40\%$).

Это согласуется с биологическими ожиданиями: экспрессия HSP70 сопровождается реорганизацией белков и изменениями в мембранных липидах нейронов.

Средние нормализованные спектры по классам представлены на рис. 6.

[Место для графиков средних SNV-спектров по трём классам (control / endo / exo) для диапазонов 1500 и 2900 с отмеченными значимыми полосами]

Рис. 6: Средние SNV-спектры трёх классов. Вертикальными пунктирными линиями отмечены биохимически значимые полосы с наибольшим вкладом в модель.

3.3 Пространство признаков: визуализация PCA

[Место для scatter-графика PC1 vs PC2 с раскраской по классам для диапазонов 1500 и 2900]

Рис. 7: Проекция спектральных карт на плоскость первых двух главных компонент (PCA, SNV-спектры). Слева: диапазон 1500 см$^{-1}$; справа: 2900 см$^{-1}$.

4 Обсуждение

Достигнутый macro $F_1 = 0.791$ демонстрирует, что рамановские спектры мозговой ткани несут устойчивую молекулярную «подпись» экспериментальной группы, различимую автоматическими методами.

Наблюдаемое превосходство стекинга над прямыми стратегиями агрегации (Soft Voting: 0.494 против 0.764) объясняется тем, что мета-классификатор обучается учитывать различные систематические смещения базовых моделей. Ни одна базовая модель в отдельности не превышала macro $F_1 = 0.55$, что указывает на принципиальную роль ансамблирования.

Класс *endo* демонстрирует наилучшую разделимость ($F_1 = 0.85$), что соответствует биологической гипотезе: эндогенная индукция HSP70 является сильным стрессовым ответом, порождающим выраженные спектральные изменения (денатурация белков, окислительные модификации липидов). Смешение *control* и *exo* несколько выше, что логично: введение экзогенного HSP70 частично нормализует молекулярный фенотип ткани.

Четыре LOAO-фолда — ограниченный объём для надёжной оценки обобщающей способности. Расширение выборки новыми животными является приоритетной задачей.

5 Заключение

В работе разработан полный пайплайн классификации рамановских спектров мозговой ткани крысы по трём экспериментальным группам. Ключевые результаты:

1. Разработана процедура предобработки, включающая коррекцию флуоресцентного фона (ALS), сглаживание (SG) и SNV-нормализацию, обеспечивающая воспроизводимое сравнение спектров разных карт.
2. Сформировано многоуровневое признаковое пространство из биохимических полос, производных, вейвлет-коэффициентов и компонент снижения размерности.
3. Применена схема LOAO-CV, исключающая утечку биологической информации между животными.
4. Обучен ансамбль из 21 базовой модели (7 алгоритмов $\times$ 3 набора признаков) с байесовской настройкой гиперпараметров.
5. Итоговый macro $F_1 = 0.791$ достигнут через стекинговый мета-классификатор с оптимизацией порогов решения.

Наиболее информативными оказались признаки амидных полос (вторичная структура белка) и соотношение CH_2/CH_3 (ненасыщенность мембранных липидов), что открывает перспективы для разработки быстрых спектральных биомаркеров нейропротекции.